Analyse de sentiment YouTube

Contexte

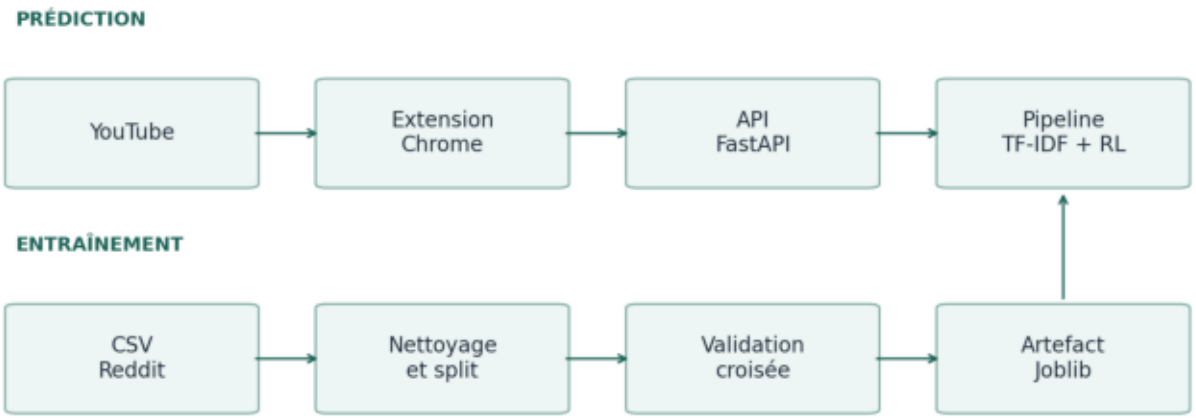
Une vidéo peut recevoir des centaines de commentaires. Le projet regroupe les prédictions négatives, neutres et positives pour aider à parcourir les réactions.

Architecture

L’extension Chrome extrait les commentaires déjà affichés. Son service worker les transmet par lots à FastAPI. Le modèle scikit-learn renvoie un sentiment et une probabilité par commentaire. Le popup présente la répartition et permet de filtrer et d’exporter les résultats.

Résumé expérimental

Le modèle 7badefffbc0d atteint 88.35% d’exactitude sur 7,315 commentaires Reddit de test. L’inférence d’un lot de 50 commentaires a un p95 de 82.60 ms. Objectifs mesurés atteints.



Données et préparation

Acquisition

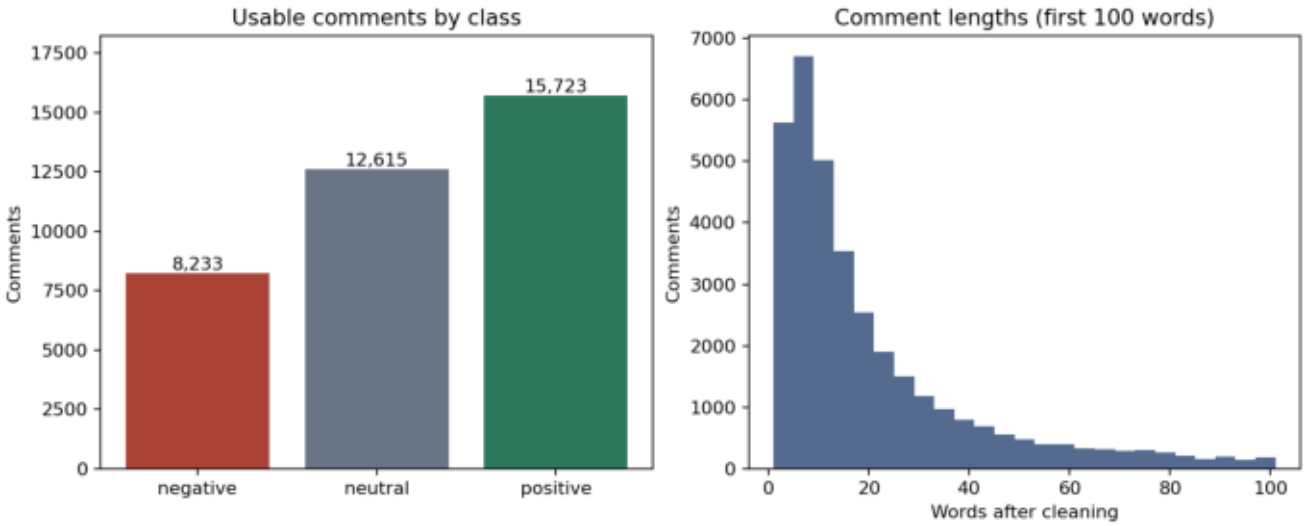
La source de référence est le fichier reddit.csv du dépôt Himanshu-1703/reddit-sentiment-analysis. Le téléchargement conserve le CSV brut et enregistre son empreinte SHA-256. La copie locale utilisée et le CSV en ligne ont été comparés : les textes normalisés et les labels sont identiques. Les colonnes clean_comment et category deviennent text et label.

Nettoyage

Normalisation Unicode, suppression des URL et mentions, conversion des emojis pris en charge en tokens et conservation des mots de négation. Les textes vides et les doublons normalisés sont supprimés avant la séparation. Les conflits de labels sont écartés.

Séparation

36,571 commentaires utilisables après préparation. La séparation stratifiée 80/20 produit 29,256 exemples d'apprentissage et 7,315 de test, avec la graine 42. Les textes identiques après normalisation ne peuvent pas se retrouver des deux côtés.



Entraînement et sélection

TF-IDF

La fréquence locale est pondérée par la rareté du terme dans les documents d’apprentissage. La recherche compare des n-grammes de mots seuls et une combinaison avec des n-grammes de caractères, utiles pour certaines variantes orthographiques.

Comparaison

Validation croisée stratifiée à trois plis. F1 macro de la référence majoritaire : 0.200. SVM linéaire : 0.847. Meilleure régression logistique : 0.854.

Optimisation

Recherche de 10 configurations par grille, notamment la régularisation C, la pondération des classes et les caractéristiques TF-IDF. La vectorisation est apprise dans chaque pli. Le choix final s’appuie sur le F1 macro de validation, puis la configuration choisie est réentraînée sur la partition d’apprentissage.

Artefacts

Le pipeline complet est utilisé par l’API. Le classificateur et le vectoriseur sont également exportés séparément. Les versions de dépendances, les paramètres et le hash du pipeline figurent dans models/metadata.json.

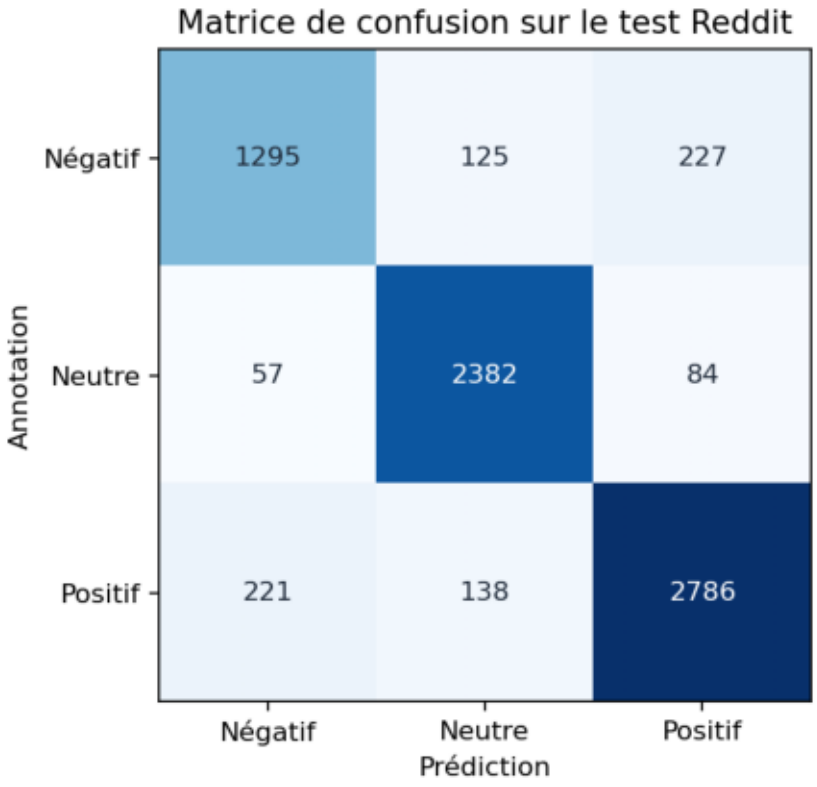
Résultats sur le test

Qualité

Exactitude 88.35%. F1 négatif 0.804, neutre 0.922, positif 0.893. F1 macro 0.873. Objectifs mesurés atteints.

Vitesse

Lots de 50 commentaires, 30 essais à chaud. Moyenne 50.85 ms et p95 82.60 ms. Cette mesure couvre le nettoyage, la vectorisation et le calcul des probabilités. Le délai HTTP est mesuré séparément.



API de prédiction

Contrat

GET /health indique si le modèle est prêt et renvoie sa version. POST /predict_batch accepte de 1 à 50 éléments id/text. Les identifiants sont uniques dans le lot et les textes sont limités à 5 000 caractères.

Prédictions

L’ordre des commentaires est conservé. Chaque prédiction contient le label, son nom et la probabilité de la classe sélectionnée. Un texte devenu vide est signalé comme ignoré et exclu du calcul des pourcentages.

Disponibilité

Le modèle est chargé une fois au démarrage et son empreinte est vérifiée. Une requête invalide renvoie 422. Un modèle indisponible donne 503. La durée et la taille du lot sont journalisées sans les textes des utilisateurs.

Configuration

Le middleware CORS peut autoriser les origines d’extension explicites. La documentation interactive générée par FastAPI est accessible sous /docs.

Extension Chrome

Collecte

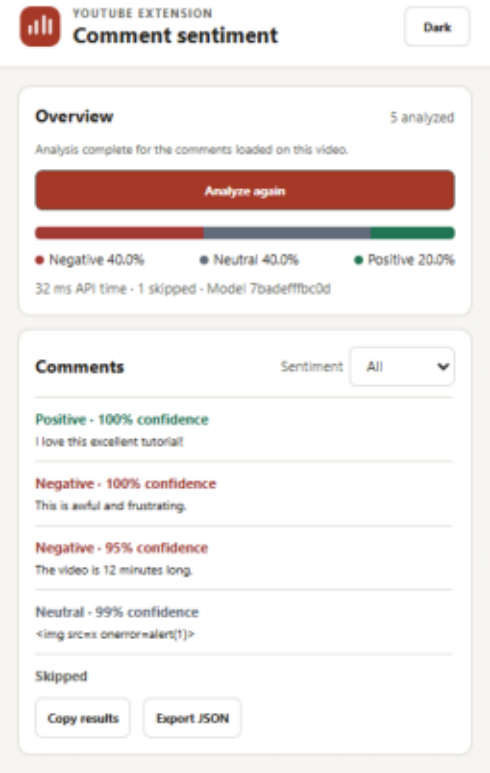
Un script de contenu lit les commentaires chargés dans la page de lecture, y compris les réponses dépliées. L'utilisateur défile pour charger davantage de commentaires avant une nouvelle analyse. Le plafond est de 250 commentaires par analyse.

Traitement

Le service worker envoie des lots de 50 et stocke leur progression par onglet et vidéo. Les erreurs réseau et les résultats partiels sont visibles après réouverture du popup.

Interface

Le popup présente une barre de répartition, des filtres, les probabilités, un thème clair/sombre, la copie et l'export JSON. Les commentaires sont insérés comme texte.



Déploiement et validation

Conteneur

Docker utilise Python 3.13, les dépendances verrouillées et un utilisateur sans privilèges. Uvicorn écoute sur le port 7860. L’image embarque le pipeline de service et ne requiert aucun téléchargement de données à l’exécution.

Mise en ligne

Le dépôt contient la configuration Hugging Face Docker Spaces et le script de publication. Le lancement de l’instance hébergée requiert un compte autorisé. Après publication, vérifier /health, un lot de prédictions et l’extension configurée avec l’origine HTTPS du Space.

Contrôles

Les tests valident les entrées API, les classes et probabilités, les textes ignorés, les erreurs, la taille maximale de lot, le regroupement des résultats et le changement de vidéo. Le test navigateur Playwright utilise une page de commentaires contrôlée et l’API locale.

Reproductibilité

Les commandes dans le README recréent les splits, le modèle, les figures et le paquet d’extension. Le workflow CI prévoit également le démarrage du conteneur et son test de santé.

Limites et pistes de travail

Transfert Reddit vers YouTube

Les scores du test Reddit quantifient la performance sur la distribution annotée de référence. Les usages, la langue et les formulations sur YouTube peuvent différer. Annoter un échantillon YouTube indépendant pour mesurer ce transfert.

Interprétation

La probabilité d'une classe est une sortie du modèle. L'ironie, les textes très courts et la langue mélangée restent difficiles. Une étude de calibration et de couverture linguistique aiderait à interpréter les scores.

Robustesse

YouTube peut modifier ses composants. L'extraction repose sur des sélecteurs explicites à vérifier sur plusieurs vidéos. La taille des lots et les limites de collecte réduisent le coût des requêtes et du rendu.

Sources et livrables

Consigne TP Cloud Computing INDIA S5, jeu Reddit indiqué dans le sujet, documentation officielle scikit-learn, FastAPI, Chrome Extensions et Hugging Face Docker Spaces. Les fichiers metrics.json et metadata.json contiennent les résultats et la provenance détaillée.